테스트 계획 및 결과 보고서

✅ 테스트 개요

> 본 테스트는 F1 입문자용 챗봇이 사용자의 질문에 대해 **정확하고 이해하기 쉬운 답변**을 제공하는지 검증하기 위해 수행하였습니다. 특히, **FIA 규정, F1 용어, 플래그, 역사, 스튜어드 판정문**을 기반으로 한 질의응답 품질과 한국어 설명 능력을 중점적으로 평가하였습니다.

테스트 목적

> 규정 기반 질의응답의 정확성 검증한국어 질문 이해 및 응답 생성 능력 검증입문자 친화적인 쉬운 설명 제공 여부 검증시스템 응답 속도 및 서비스 안정성 검증

✅ 테스트 항목

2-1. 질의응답 정확성

> FIA 규정을 근거로 정확한 답변을 제공하는가?
>
> 용어, 플래그, 역사, 판정문 관련 질문에도 올바르게 응답하는가?

2-2. 한국어 자연어 이해 능력

> 한국어 질문 의도를 정확히 파악하는가?
>
> 동일 의미의 다양한 표현에도 적절히 응답하는가?

2-3. 쉬운 설명 변환 능력

> 초보자가 이해하기 어려운 기술 용어나 규정을 쉽게 풀어서 설명하는가?
>
> 불필요하게 어려운 표현 없이 자연스럽게 설명하는가?

2-4. 응답 시간 및 성능

> 평균 응답 시간이 10초 이내인가?
>
> 질문 유형이 달라져도 일관된 속도로 응답하는가?

✅ 테스트 케이스

테스트 ID	질문	테스트 목적
F1QA001	F1 바닥에 있는 플랭크는 그냥 보호판 같은 건가요? 두께 기준도 있나요?	기술 규정 기반 상세 조건 이해 평가
F1QA002	피트레인에서는 무조건 시속 80km 이하로 달려야 하나요? 넘으면 바로 벌점 받나요?	경기 운영 규정 및 제재 방식 이해 평가
F1QA003	폭염 경기에서는 드라이버 냉각장치를 아무거나 달아도 되나요?	운영 규정 기반 조건 이해 평가
F1QA004	더블 웨이브 옐로우가 나온 구간에서 예선 랩을 계속 밀어붙이면 어떻게 되나요?	스포츠 규정 기반 제재 이해 평가
F1QA005	2026년에 말하는 '액티브 에어로'는 예전 DRS랑 같은 건가요?	용어·개념 비교 설명 평가
F1QA006	에어로 레이크는 차 성능을 높이는 부품인가요?	용어 정의 및 오개념 교정 평가
F1QA007	F1 예산 제한은 그냥 "돈을 이 이상 쓰면 안 된다"는 뜻인가요?	재무 규정 맥락 이해 평가
F1QA008	왜 1952~1953년에는 원래 F1 규정이 아니라 다른 규정이 쓰였나요?	역사적 배경 설명 능력 평가

평가 기준

- **정확성**: 규정/원문과 일치하는가?
- **이해성**: 한국어 문장이 자연스럽고 의미 전달이 명확한가?
- **친절성**: 초보자도 이해할 수 있도록 쉬운 표현을 사용하는가?
- **응답시간**: 응답 생성 시간이 10초 이내인가?

`평가는 각 문항별로 수동 검토 방식으로 진행하였으며, 필요 시 원문 규정과 대조하여 사실 여부를 재확인하였습니다.`

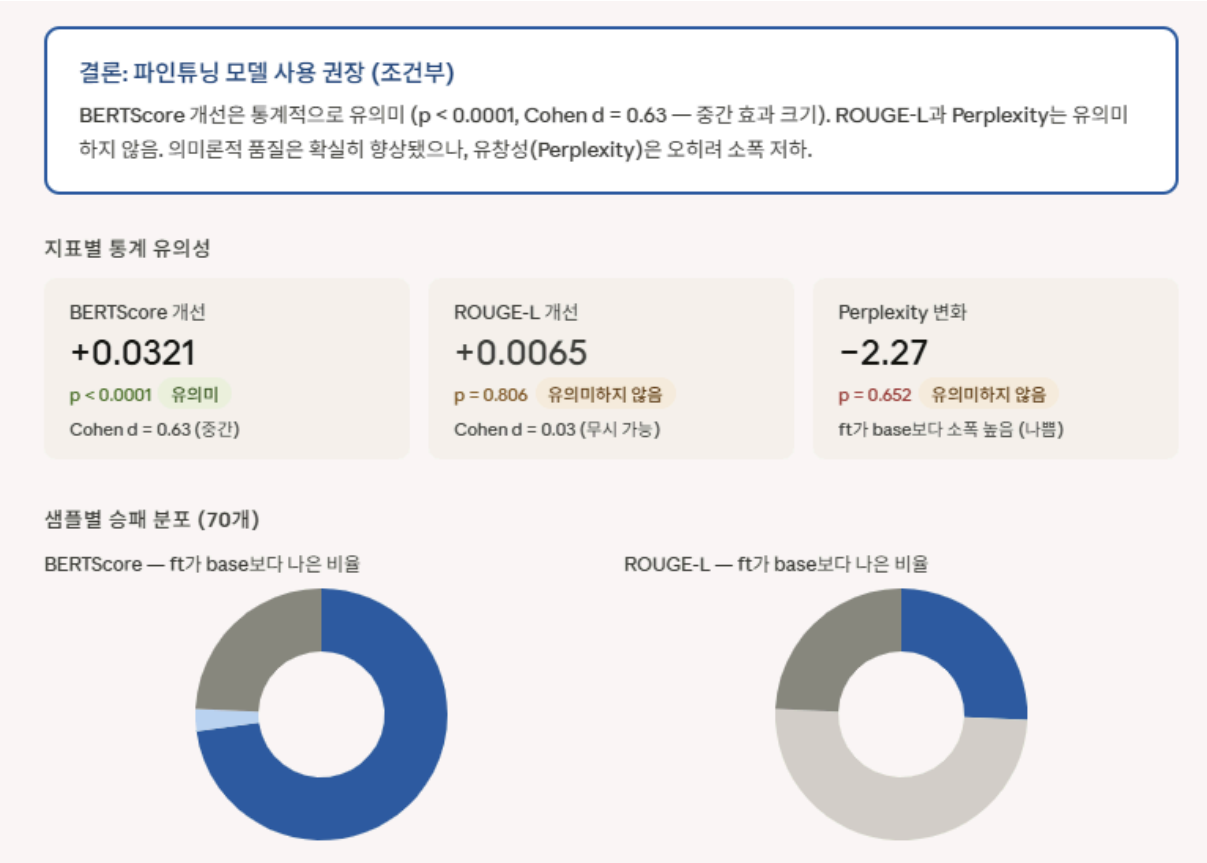

> 모델 평가는 **BERTScore**, **ROUGE-L**, **Perplexity**를 사용하여 각각 의미 유사도, 표현 유사도, 문장 자연스러움을 함께 확인했습니다.
>
> 평가 결과, 파인튜닝 모델은 **BERTScore에서 통계적으로 유의미한 향상**을 보여 의미적 답변 품질이 개선된 것으로 확인되었습니다.
>
> 반면 **ROUGE-L**과 **Perplexity**에서는 유의미한 차이가 크지 않아, 표현 유사도와 유창성 측면의 개선은 제한적이었습니다.
>
> 따라서 본 프로젝트에서는 **의미 정확도가 중요한 질의에 대해 파인튜닝 모델을 우선적으로 활용하는 것이 적절하다**고 판단했습니다.

✅ 테스트 결과

> 테스트 결과, 챗봇은 **대다수의 규정 기반 질문에 대해 정확한 답변**을 제공하였으며,
>
> 용어 설명과 조건형 질문에서도 **안정적인 성능**을 보였습니다.
>
> 특히, 단순 정의형 질문과 조문 근거가 명확한 질문에서는 **높은 정확도**를 보였습니다.
>
> 하지만 응답 시간이 평균 **10~20초의 시간**이 소요되었습니다.

확인된 개선 필요 사항

> 일부 기술 규정 질문에서 답변이 조문 수준으로 딱딱하게 출력되는 경우가 있습니다.
>
> 예외 조항이 포함된 질문에서는 설명이 길어져 초보자 관점에서 다소 어렵게 느껴질 수 있습니다.
>
> 한국어 문장은 전반적으로 자연스러웠으나, 일부 용어는 추가적인 쉬운 풀이가 필요합니다.
>
> 응답 생성 시간이 비교적 오래 걸리므로, 최적화가 필요합니다.

✅ 종합 평가

> 본 테스트를 통해 F1 입문자용 챗봇은 입문자 사용자를 대상으로 한 **규정 설명 서비스로서 기본적인 정확성과 설명 가능성**을 확보하였음을 확인하였습니다.
>
> 향후에는 **예외 조항 설명 간소화**, **기술 용어의 쉬운 재서술**, **응답 속도 최적화**를 통해 사용자 친화성을 더욱 높일 필요가 있습니다.